

Προηγμένη Τεχνητή Νοημοσύνη Πακέτο Ασκήσεων - Weka

Παναγή Αντρέας

Τμήμα Μαθηματικών
Εθνικόν και Καποδιστριακόν Πανεπιστήμιον Αθηνών
Αθήνα, Ελλάδα *

Ιανουάριος 2026



ΕΛΛΗΝΙΚΗ ΔΗΜΟΚΡΑΤΙΑ
Εθνικόν και Καποδιστριακόν
Πανεπιστήμιο Αθηνών

* Στοιχειοδότηση με χρήση ΧΕΛΑΤΕΧ

Περιεχόμενα

1	Εισαγωγή και Περιγραφή Ασκήσεων	1
2	Επιβλεπόμενες Μέθοδοι Ταξινόμησης στο Nursery Dataset	2
2.1	Δέντρα Απόφασης (J48)	2
2.2	Πολυεπίπεδο Νευρωνικό Δίκτυο (MultilayerPerceptron)	2
2.3	Μάθηση με Στιγμιότυπα (IBk)	3
2.4	Αφελής Ταξινομητής Bayes (NaiveBayes)	3
2.5	Meta-learning: AdaBoostM1 (Boosting)	4
2.6	Συμπεράσματα και Συγκρίσεις	5
3	Μη Επιβλεπόμενη Μάθηση: Συσταδοποίηση	6
3.1	SimpleKMeans	6
3.2	Cobweb	6
3.3	Συμπεράσματα	7
4	Κατηγοριοποίηση Κειμένου	8
4.1	Πειραματικό Πρωτόκολλο	8
4.2	Διερεύνηση Μεθόδων και Αποτυχημένες Βελτιώσεις	8
4.3	Τελικό Αποτέλεσμα: NaiveBayesMultinomial στο tr31.mat	8
4.4	Σύνοψη Αποτελεσμάτων	9

1 Εισαγωγή και Περιγραφή Ασκήσεων

Σκοπός της παρούσας εργασίας είναι η μελέτη και σύγκριση διαφορετικών μεθόδων μηχανικής μάθησης ως προς την εφαρμοσιμότητα και την καταλληλότητά τους σε προβλήματα ταξινόμησης και συσταδοποίησης. Για την υλοποίηση των πειραμάτων χρησιμοποιήθηκε το λογισμικό *WEKA* (Waikato Environment for Knowledge Analysis), το οποίο παρέχει ενιαίο περιβάλλον για προεπεξεργασία δεδομένων, εκπαίδευση ταξινομητών, αξιολόγηση μοντέλων και σύγκριση μεθόδων.

Η εργασία χωρίζεται σε τρία μέρη. Στο πρώτο μέρος εξετάζονται επιβλεπόμενες μέθοδοι ταξινόμησης στο σύνολο δεδομένων *nursery.arff*, το οποίο αφορά την αξιολόγηση αιτήσεων εγγραφής παιδιών σε νηπιαγωγείο και περιλαμβάνει κατηγορικά χαρακτηριστικά και μία διακριτή μεταβλητή κλάσης. Μελετώνται οι αλγόριθμοι J48 (δέντρα απόφασης), Multilayer Perceptron (πολυεπίπεδα νευρωνικά δίκτυα), IBk (μάθηση με στιγμιότυπα) και Naive Bayes, καθώς και μία μέθοδος meta-learning της επιλογής μας. Για κάθε μέθοδο πραγματοποιούνται δοκιμές με διαφορετικές ρυθμίσεις παραμέτρων με στόχο τη βελτίωση της απόδοσης.

Στο δεύτερο μέρος εφαρμόζεται μία μη επιβλεπόμενη μέθοδος συσταδοποίησης στο ίδιο σύνολο δεδομένων, αγνοώντας την πληροφορία της κλάσης, ώστε να μελετηθεί η εσωτερική δομή των δεδομένων και η δημιουργία συστάδων βάσει ομοιότητας.

Στο τρίτο μέρος εξετάζεται ένα πρόβλημα κατηγοριοποίησης κειμένων από τα διαθέσιμα σύνολα του *19MclassTextWc.zip*. Επιλέγεται κατάλληλη διαδικασία προεπεξεργασίας κειμένου και εφαρμόζεται μία επιβλεπόμενη μέθοδος ταξινόμησης με στόχο το ποσοστό σωστά ταξινομημένων στιγμιοτύπων, με διασταυρωμένη επικύρωση 10 τμημάτων (10-fold cross-validation), να υπερβαίνει το 90%.

2 Επιβλεπόμενες Μέθοδοι Ταξινόμησης στο Nursery Dataset

Στο παρόν κεφάλαιο μελετώνται επιβλεπόμενες μέθοδοι ταξινόμησης στο σύνολο δεδομένων `nursery.arff`. Το σύνολο περιλαμβάνει 12960 στιγμιότυπα και 9 κατηγορικά (nominal) γνωρίσματα, εκ των οποίων το `class` αποτελεί τη μεταβλητή-στόχο. Τα υπόλοιπα γνωρίσματα περιγράφουν χαρακτηριστικά που σχετίζονται με την αξιολόγηση αιτήσεων εγγραφής παιδιών σε νηπιαγωγείο.

Για λόγους συγκρισιμότητας, όλα τα μοντέλα αξιολογούνται με την ίδια διαδικασία διασταυρωμένης επικύρωσης 10 τμημάτων (10-fold cross-validation) στο ίδιο σύνολο δεδομένων. Επιπλέον, το `nursery` παρουσιάζει έντονη ανισορροπία κλάσεων: η κλάση `recommend` εμφανίζεται μόλις σε 2 στιγμιότυπα, γεγονός που καθιστά αναμενόμενο το μηδενικό *recall* της σε πολλές ρυθμίσεις/αλγόριθμους. Στις επόμενες υποενότητες παρουσιάζονται οι μέθοδοι που εξετάστηκαν, οι βασικές παράμετροι που ρυθμίστηκαν και τα αποτελέσματα που προέκυψαν.

2.1 Δέντρα Απόφασης (J48)

Στην πρώτη μέθοδο εφαρμόσαμε τον ταξινομητή J48 (υλοποίηση του C4.5 στο WEKA) στο σύνολο δεδομένων `nursery.arff`, χρησιμοποιώντας διασταυρωμένη επικύρωση 10 τμημάτων (10-fold cross-validation). Εξετάσαμε συστηματικά την επίδραση δύο βασικών υπερπαραμέτρων:

- (i) του *confidence factor* C , που ελέγχει το επίπεδο pruning (μεγαλύτερο $C \Rightarrow$ λιγότερο επιθετικό pruning και άρα πιο μεγάλα δέντρα), και
- (ii) του M , που ορίζει τον ελάχιστο αριθμό παραδειγμάτων ανά φύλλο (μεγαλύτερο $M \Rightarrow$ απλούστερα δέντρα).

Τα αποτελέσματα δείχνουν ότι η αύξηση του C βελτιώνει την ακρίβεια (από 95.99% σε 97.72%) με κόστος σημαντική αύξηση της πολυπλοκότητας (Leaves/Size), ενώ η αύξηση του M μειώνει έντονα το μέγεθος του δέντρου αλλά οδηγεί σε πτώση της ακρίβειας. Η κλάση `recommend` είναι εξαιρετικά σπάνια (μόλις 2 στιγμιότυπα), άρα το *recall* εμφανίζεται μηδενικό σε όλες τις δοκιμές.

Πίνακας 1: J48: Επίδραση του confidence factor C (10-fold CV, $M = 2$).

C	Acc. (%)	κ	Leaves	Size	Recall(recommend)
0.05	95.9954	0.9411	221	327	0.000
0.10	96.1806	0.9438	341	487	0.000
0.25	97.0525	0.9568	359	511	0.000
0.50	97.7160	0.9665	524	732	0.000

Πίνακας 2: J48: Επίδραση του minimum instances per leaf M (10-fold CV, $C = 0.25$).

M	Acc. (%)	κ	Leaves	Size	Recall(recommend)
1	97.0602	0.9569	359	511	0.000
5	95.8333	0.9388	263	383	0.000
10	95.1312	0.9283	167	255	0.000

2.2 Πολυεπίπεδο Νευρωνικό Δίκτυο (MultilayerPerceptron)

Για τα νευρωνικά δίκτυα χρησιμοποιήθηκε ο ταξινομητής `weka.classifiers.functions.MultilayerPerceptron`, δηλαδή ένα πολυεπίπεδο δίκτυο προώθησης (feed-forward) με σιγμοειδείς συναρτήσεις ενεργοποίησης, το οποίο εκπαιδεύεται με αλγόριθμο οπισθοδιάδοσης (backpropagation). Η αξιολόγηση έγινε

με διασταυρωμένη επικύρωση 10 τμημάτων (10-fold CV) πάνω στο `nursery.arff`. Αρχικά κρατήσαμε σταθερές τις βασικές παραμέτρους εκπαίδευσης ($L = 0.3$ learning rate, $M = 0.2$ momentum, $\text{seed}=1$) και εξετάσαμε την επίδραση του αριθμού epochs (N). Για την επιλογή $H = a$ (αυτόματη ρύθμιση κρυφών μονάδων από το Weka), η επίδοση παρέμεινε ουσιαστικά ίδια για $N = 200, 500, 1000$, κάτι που υποδηλώνει ότι το μοντέλο συγκλίνει γρήγορα και ότι ο αριθμός επαναλήψεων δεν είναι ο καθοριστικός παράγοντας για τη συγκεκριμένη ρύθμιση.

Στη συνέχεια, κρατώντας σταθερό το $N = 500$, διερευνήσαμε διαφορετικές αρχιτεκτονικές μέσω της παραμέτρου H . Οι επιλογές $H = i$ και $H = t$ οδήγησαν σε χαμηλότερη συνολική ακρίβεια και, κυρίως, σε πολύ χαμηλό recall για την κλάση `very_recom`, με βασικό μοτίβο σφαλμάτων τη σύγχυση `very_recom` $\rightarrow$ `priority`. Αντίθετα, όταν αυξήσαμε το πλήθος των κρυφών νευρώνων ($H = 10$ και ιδιαίτερα $H = 20$), η απόδοση βελτιώθηκε σημαντικά, φτάνοντας σχεδόν τέλεια ταξινόμηση (99.9769% accuracy και $\kappa = 0.9997$) και πλήρη ανάκτηση της `very_recom` (recall 1.000). Τέλος, σε όλες τις δοκιμές η κλάση `recommend` παραμένει πρακτικά μη ανιχνεύσιμη (recall 0), κάτι που είναι αναμενόμενο επειδή εμφανίζεται μόνο σε 2 στιγμιότυπα στο `dataset`, άρα είναι εξαιρετικά δύσκολο να μάθει το μοντέλο στα πλαίσια 10-fold CV.

Πίνακας 3: MLP: Επίδραση των epochs N (10-fold CV, $H = a$, $L = 0.3$, $M = 0.2$, $\text{seed}=1$).

N	Acc. (%)	κ	MAE	RMSE	Recall(very_recom)
200	98.4645	0.9773	0.0043	0.0402	0.399
500	98.4645	0.9773	0.0038	0.0400	0.399
1000	98.4645	0.9773	0.0036	0.0398	0.399

Πίνακας 4: MLP: Επίδραση της αρχιτεκτονικής κρυφών νευρώνων H (10-fold CV, $L = 0.3$, $M = 0.2$, $N = 500$, $\text{seed}=1$).

H	Acc. (%)	κ	MAE	RMSE	Recall(very_recom)	Recall(recommend)
a	98.4645	0.9773	0.0038	0.0400	0.399	0.000
i	97.9552	0.9698	0.0048	0.0459	0.198	0.000
t	97.7083	0.9661	0.0052	0.0485	0.101	0.000
5	97.8086	0.9678	0.0121	0.0823	0.646	0.000
10	99.6528	0.9949	0.0021	0.0274	0.899	0.000
20	99.9769	0.9997	0.0009	0.0108	1.000	0.000

2.3 Μάθηση με Στιγμιότυπα (IBk)

Για τη μάθηση με στιγμιότυπα χρησιμοποιήθηκε ο ταξινομητής IBk (k-NN) με 10-fold cross-validation. Μελετήθηκε η επίδραση του αριθμού γειτόνων k και εναλλακτικές επιλογές απόστασης/στάθμισης. Στα περισσότερα πειράματα (για k έως 11), τα αποτελέσματα παρέμειναν πρακτικά ίδια, γεγονός που υποδηλώνει ότι για το συγκεκριμένο σύνολο δεδομένων η τοπική πλειοψηφία στα γειτονικά στιγμιότυπα είναι ιδιαίτερα σταθερή. Για πολύ μεγάλο k (π.χ. $k = 21$) η απόδοση μειώνεται αισθητά.

Συμπερασματικά, ο IBk πετυχαίνει υψηλή ακρίβεια ($\approx 98.38\%$) για ένα ευρύ φάσμα τιμών του k , ενώ οι παραλλαγές απόστασης/στάθμισης (στις δοκιμές που έγιναν) δεν επέφεραν ουσιαστική βελτίωση. Η αύξηση του k σε πολύ υψηλές τιμές οδηγεί σε υποβάθμιση της απόδοσης, όπως φαίνεται για $k = 21$.

2.4 Αφελής Ταξινομητής Bayes (NaiveBayes)

Ο NaiveBayes αξιολογήθηκε με 10-fold cross-validation σε τρεις παραλλαγές (default, -D, -K). Και στις τρεις περιπτώσεις τα αποτελέσματα ήταν ίδια (Accuracy 90.3241%, $\kappa = 0.8567$), κάτι αναμενόμενο επειδή το `dataset` `nursery` αποτελείται από ονομαστικά χαρακτηριστικά. Συνεπώς, ούτε η

Πίνακας 5: IBk: Επίδραση του αριθμού γειτόνων k (baseline ρυθμίσεις, χωρίς στάθμιση).

k	Acc. (%)	κ	MAE	RMSE
1	98.3796	0.9761	0.0859	0.1466
3	98.3796	0.9761	0.0859	0.1466
5	98.3796	0.9761	0.0859	0.1466
7	98.3796	0.9761	0.0859	0.1466
9	98.3796	0.9761	0.0859	0.1466
11	98.3796	0.9761	0.0859	0.1466
15	98.3102	0.9751	0.0877	0.1491
21	95.9954	0.9407	0.1364	0.2064

Πίνακας 6: IBk: Απόσταση και στάθμιση για σταθερό $k = 11$ (δείγμα συγκριτικών runs).

Distance	Weighting	Acc. (%)	κ	MAE	RMSE
Euclidean	none	98.3796	0.9761	0.0859	0.1466
Euclidean	1/distance	98.3796	0.9761	0.0859	0.1466
Manhattan	none	98.3796	0.9761	0.0859	0.1466
Manhattan	1/distance	98.3796	0.9761	0.0859	0.1466
Manhattan	1-distance	98.3796	0.9761	0.0859	0.1466

supervised διακριτοποίηση (-D) ούτε ο kernel estimator (-K, που ωφελεί κυρίως σε αριθμητικά γνωρίσματα) επηρέασαν την απόδοση. Το μεγαλύτερο μέρος των λαθών προέρχεται από σύγχυση μεταξύ των κλάσεων `very_recom` και `priority`.

Πίνακας 7: NaiveBayes: Έλεγχος παραλλαγών (10-fold CV) στο `nursery`.

Ρυθμίσεις	Acc. (%)	κ
Default	90.3241	0.8567
-D (supervised discretization)	90.3241	0.8567
-K (kernel estimator)	90.3241	0.8567

2.5 Meta-learning: AdaBoostM1 (Boosting)

Για να εξετάσουμε μία μέθοδο *meta-learning*, εφαρμόσαμε τον AdaBoostM1 στο σύνολο δεδομένων `nursery.arff`, με **10-fold cross-validation**. Η βασική ιδέα του boosting είναι ότι εκπαιδεύει διαδοχικά πολλούς «αδύναμους» ταξινομητές, δίνοντας μεγαλύτερο βάρος στα παραδείγματα που ταξινομήθηκαν λάθος σε προηγούμενους γύρους, και στη συνέχεια συνδυάζει τις προβλέψεις τους.

Αρχικά χρησιμοποιήθηκε ως base learner το DecisionStump. Παρότι το boosting αυξάνει την εκφραστικότητα, το αποτέλεσμα παρέμεινε χαμηλό (περίπου 66.25% accuracy) και δεν βελτιώθηκε με αύξηση των επαναλήψεων I , γεγονός που δείχνει ότι ένα stump δεν είναι επαρκές για να αποτυπώσει τις απαραίτητες σχέσεις στο `nursery`.

Στη συνέχεια, ως base learner χρησιμοποιήθηκε ο J48 με παραμέτρους $C = 0.25$ και $M = 2$. Σε αυτή την περίπτωση, το boosting οδήγησε σε πολύ υψηλή απόδοση: η ακρίβεια αυξάνεται καθώς αυξάνεται ο αριθμός επαναλήψεων I , φτάνοντας 99.784% για $I = 100$ (με $\kappa = 0.9968$). Παρατηρείται επίσης σημαντική βελτίωση στην κλάση `very_recom`, ενώ η κλάση `recommend` παραμένει πρακτικά μη ανιχνεύσιμη ($recall \approx 0$ βλέποντας ότι εμφανίζεται μόνο σε 2 στιγμιότυπα).

Πίνακας 8: AdaBoostM1 με base learner DecisionStump (10-fold CV, seed=1).

I	Acc. (%)	κ	MAE	RMSE
10	66.2500	0.4959	0.2065	0.2889
25	66.2500	0.4959	0.2061	0.2887
50	66.2500	0.4959	0.2061	0.2887
100	66.2500	0.4959	0.2061	0.2887

Πίνακας 9: AdaBoostM1 με base learner J48 ($C = 0.25$, $M = 2$), 10-fold CV, seed=1.

I	Acc. (%)	κ	MAE	RMSE	Recall(very_recom)	Recall(recommend)
10	99.5062	0.9928	0.0020	0.0415	0.960	0.000
25	99.7068	0.9957	0.0012	0.0340	0.970	0.000
50	99.7608	0.9965	0.0010	0.0309	0.976	0.000
100	99.7840	0.9968	0.0009	0.0293	0.979	0.000

2.6 Συμπεράσματα και Συγκρίσεις

Όλες οι μέθοδοι αξιολογήθηκαν με **10-fold cross-validation** στο `nursery.arff`. Συνολικά, οι καλύτερες επιδόσεις προήλθαν από **MLP** και **AdaBoostM1 με βάση J48**, που έφτασαν σε σχεδόν τέλεια ταξινόμηση, ενώ ο **J48** μόνος του παρέμεινε πολύ ανταγωνιστικός και ερμηνεύσιμος. Ο **IBk** έδωσε σταθερά υψηλή ακρίβεια για πολλά k , αλλά χωρίς να ξεπεράσει τα καλύτερα μοντέλα. Ο **Naive Bayes** υστερεί αισθητά, με κύρια σύγχυση `very_recom` $\rightarrow$ `priority`. Τέλος, η κλάση `recommend` έχει πρακτικά *recall* 0 σε όλες τις μεθόδους λόγω ακραίας ανισορροπίας (μόνο 2 στιγμιότυπα).

Πίνακας 10: Σύνοψη αποτελεσμάτων (10-fold CV).

Μέθοδος (ενδεικτική ρύθμιση)	Acc. (%)	κ
J48 ($C = 0.50$, $M = 2$)	97.7160	0.9665
MLP ($H = 20$, $N = 500$)	99.9769	0.9997
IBk ($k = 5$)	98.3796	0.9761
NaiveBayes (default)	90.3241	0.8567
AdaBoostM1+J48 ($I = 100$)	99.7840	0.9968

3 Μη Επιβλεπόμενη Μάθηση: Συσταδοποίηση

Στο κεφάλαιο αυτό εφαρμόστηκαν μη επιβλεπόμενες μέθοδοι συσταδοποίησης στο `nursery.arff`. Η αξιολόγηση έγινε στο training set (*evaluate on training data*) και κρατήσαμε σταθερό seed ($S = 1$), ώστε οι δοκιμές να είναι όσο γίνεται συγκρίσιμες. Σημειώνεται ότι για τη συσταδοποίηση αγνοήθηκε η κλάση (`class`) κατά τον υπολογισμό της ομοιότητας, ώστε τα αποτελέσματα να αντανακλούν αποκλειστικά τα χαρακτηριστικά εισόδου.

3.1 SimpleKMeans

Χρησιμοποιήθηκε ο SimpleKMeans και μελετήθηκε η επίδραση του αριθμού συστάδων k . Με ευκλείδεια απόσταση παρατηρείται αναμενόμενη μείωση του within-cluster σφάλματος (SSE) όσο αυξάνει το k , καθώς περισσότερες συστάδες επιτρέπουν λεπτομερέστερη προσαρμογή στα δεδομένα.

Πίνακας 11: SimpleKMeans (seed=1, max iterations $I = 500$): επίδραση του k (Euclidean).

k	Iterations	Within-cluster SSE
2	4	65911.0
3	2	62180.0
4	2	60553.0
5	2	58357.0
6	2	55104.0
7	2	52755.0
8	2	50955.0
9	2	49579.0
10	2	48597.0

Επιπλέον, έγιναν ενδεικτικές δοκιμές με Manhattan απόσταση για $k = 4, 5, 6, 7$. Στις συγκεκριμένες ρυθμίσεις, το reported objective (sum of within-cluster distances) βρέθηκε αριθμητικά ίδιο με τα αντίστοιχα runs, χωρίς να προκύψει ουσιαστική διαφοροποίηση ως προς την ποιότητα συσταδοποίησης.

Πίνακας 12: SimpleKMeans (seed=1, $I = 500$): ενδεικτικά runs με Manhattan.

k	Iterations	Sum within-cluster distances
4	2	60553.0
5	2	58357.0
6	2	55104.0
7	2	52755.0

3.2 Cobweb

Δοκιμάστηκε επίσης ο Cobweb, ένας ιεραρχικός αλγόριθμος εννοιολογικής συσταδοποίησης (incremental) που παράγει δενδροειδή δομή. Στο `nursery` το παραγόμενο δέντρο ήταν πολύ μεγάλο, οπότε το πλήρες output δεν είναι πρακτικό να ενσωματωθεί αυτούσιο στην αναφοράς.

Με τις ρυθμίσεις `-A 1.0 -C 0.0028209479 -S 1` προέκυψαν: *Number of merges: 4861, Number of splits: 3758, Number of clusters: 19518*, και χρόνος εκπαίδευσης *5.54 sec*. Ο πολύ μεγάλος αριθμός συστάδων υποδηλώνει υπερ-κατατμημένη ομαδοποίηση (πολλές συστάδες με ελάχιστα στιγμιότυπα), κάτι που δυσκολεύει την ερμηνεία.

3.3 Συμπεράσματα

Για τη συσταδοποίηση, ο SimpleKMeans εμφάνισε τη συνήθη συμπεριφορά: όσο αυξάνει το k , το within-cluster σφάλμα μειώνεται, άρα οι συστάδες γίνονται πιο «σφιχτές», με κόστος όμως μικρότερη συνοπτικότητα/ερμηνευσιμότητα. Αντίθετα, ο Cobweb παράγαγε πολύ μεγάλο αριθμό συστάδων και σύνθετη ιεραρχία, γεγονός που δείχνει ότι (τουλάχιστον με τις συγκεκριμένες παραμέτρους) δεν προσφέρει εύκολα ερμηνεύσιμη σύνοψη της δομής των δεδομένων.

4 Κατηγοριοποίηση Κειμένου

Στο παρόν τμήμα εξετάζουμε την κατηγοριοποίηση κειμένου με χρήση του Weka, αξιοποιώντας τυπικές προσεγγίσεις για αναπαράσταση τύπου Bag-of-Words/TF-IDF και μοντέλα επιβλεπόμενης μάθησης. Στόχος ήταν να επιτευχθεί ακρίβεια άνω του 90%, μέσω συστηματικής διερεύνησης διαφορετικών ταξινομητών και τεχνικών προεπεξεργασίας.

4.1 Πειραματικό Πρωτόκολλο

Όλες οι αξιολογήσεις πραγματοποιήθηκαν με **10-fold stratified cross-validation**, ώστε τα αποτελέσματα να είναι συγκρίσιμα και να μειώνεται η εξάρτηση από μια συγκεκριμένη διαίρεση train/test. Για κάθε run καταγράφουμε κυρίως την *accuracy* (Correctly Classified Instances), καθώς και δείκτες όπως *Kappa* και τα σφάλματα *MAE/RMSE* όπου είναι διαθέσιμα.

4.2 Διερεύνηση Μεθόδων και Αποτυχημένες Βελτιώσεις

Ξεκινήσαμε με βασικά μοντέλα, δοκιμάζοντας τόσο γραμμικούς ταξινομητές όσο και πιθανοκρατικές προσεγγίσεις:

- **SVM (SMO):** Δοκιμάστηκαν διαφορετικές τιμές της παραμέτρου C (π.χ. $C \in \{1, 10, 100, 1000\}$). Παρότι η μέθοδος είναι ισχυρή σε προβλήματα κειμένου, στα συγκεκριμένα datasets τα αποτελέσματα παρέμειναν σε σαφώς χαμηλότερα επίπεδα από τον στόχο των 90%.
- **Νευρωνικά (MLP):** Πραγματοποιήθηκαν runs με κανονικοποίηση και επιλογή χαρακτηριστικών, καθώς και με διαφορετικές ρυθμίσεις hidden layer/epochs. Παρατηρήθηκε βελτίωση έναντι ορισμένων baseline runs, όμως η επίδοση δεν σταθεροποιήθηκε σε επίπεδα που να ξεπερνούν το 90%.
- **Attribute Selection:** Εξετάστηκε επιλογή χαρακτηριστικών με CFSSubsetEval + BestFirst. Η τεχνική αυτή δεν οδήγησε σε συστηματική υπεροχή: σε αρκετές περιπτώσεις η βελτίωση ήταν μικρή ή μηδενική, ενώ δεν «έκλεισε» το κενό προς τον στόχο. Ενδεικτικά, στο oh0.mat η ακρίβεια παρέμεινε κάτω από το 90%.

Συνολικά, παρότι δοκιμάστηκε συνδυασμός διαφορετικών ταξινομητών και επιλογής χαρακτηριστικών, στα πρώτα datasets οι επιδόσεις κινήθηκαν γύρω στο 75%–89% και δεν επιτεύχθηκε ο επιθυμητός στόχος.

4.3 Τελικό Αποτέλεσμα: NaiveBayesMultinomial στο tr31.mat

Το καλύτερο αποτέλεσμα προέκυψε στο dataset tr31.mat με τον ταξινομητή NaiveBayesMultinomial. Το dataset περιλαμβάνει **927 instances** και **10129 attributes**. Με 10-fold stratified cross-validation πετύχαμε:

- **Accuracy:** 94.6063% (877/927 σωστά, 50 λάθη),
- **Kappa:** 0.928,
- **MAE:** 0.0154, **RMSE:** 0.1238.

Το αποτέλεσμα αυτό **ξεπερνά τον στόχο του 90%** και αποτελεί την τελική/καλύτερη επίδοση της πειραματικής διερεύνησης. Παρατηρείται ωστόσο ότι για την κλάση 310 δεν υπήρξε ουσιαστική επιτυχία (TP rate = 0), πιθανόν λόγω πολύ μικρού πλήθους δειγμάτων (στην confusion matrix εμφανίζεται πρακτικά μία πραγματική εμφάνιση), άρα η αξιολόγηση σε αυτή την κλάση δεν είναι στατιστικά ισχυρή.

4.4 Σύνοψη Αποτελεσμάτων

Ο Πίνακας 13 συνοψίζει τις βασικές δοκιμές και τις αντίστοιχες ακρίβειες.

Πίνακας 13: Σύνοψη αποτελεσμάτων κατηγοριοποίησης κειμένου (10-fold CV).

Dataset	Μέθοδος	Ρυθμίσεις/Filters	Acc. (%)
re0.mat	SMO (SVM)	Linear, $C=1$	75.47
re0.mat	SMO (SVM)	Linear, $C=10$	77.06
re0.mat	SMO (SVM)	Linear, $C=100$	77.13
re0.mat	SMO (SVM)	Linear, $C=1000$	76.00
rel.mat	SMO (SVM)	Linear, $C=1$	74.29
rel.mat	MLP	Normalize + AttrSel(CFS+BestFirst), $H=200$, $N=500$	78.33
tr1l.mat	NaiveBayesMultinomial	baseline	84.78
tr1l.mat	RandomForest	$I=200$, $S=1$	83.09
tr1l.mat	NaiveBayesMultinomial	AttrSel(CFS+BestFirst)	87.20
oh0.mat	NaiveBayesMultinomial	baseline	89.03
tr3l.mat	NaiveBayesMultinomial	baseline	94.61

Συμπέρασμα. Παρά τις δοκιμές με SMO/MLP και την εφαρμογή επιλογής χαρακτηριστικών, η πιο αποδοτική λύση για τα διαδέσιμα δεδομένα ήταν ο NaiveBayesMultinomial. Ειδικά στο tr3l.mat επιτεύχθηκε ακρίβεια **94.61%**, που αποτελεί και το τελικό αποτέλεσμα της εργασίας.