

Ειδικά Θέματα Αλγορίθμων: Αλγοριθμική Επιστήμη Δεδομένων

Πρώτη Σειρά Γραπτών Ασκήσεων

Παναγή Αντρέας
Α.Μ. : 7115 1424 00008

Π.Μ.Σ. - ΑΛΜΑ

Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών
Εθνικό Μετσόβιο Πολυτεχνείο
Αθήνα, Ελλάδα *

Μάιος 2024



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ

Περιεχόμενα

Άσκηση 1	1
Εκφώνηση	1
Λύση	1
Άσκηση 2	4
Εκφώνηση	4
Λύση	4
Άσκηση 3	5
Εκφώνηση	5
Άσκηση 6.3.1	5
Άσκηση 6.3.4	5
Λύση	6
Λύση 6.3.1	6
Λύση 6.3.4	6
Άσκηση 4	7
Εκφώνηση	7
Λύση	7
Άσκηση 5	8
Εκφώνηση	8
Λύση	8
Άσκηση 6: 7.2.2	11
Εκφώνηση	11
Λύση	11
Άσκηση 7: 7.2.3	12
Εκφώνηση	12
Λύση	12
Άσκηση 8: 7.2.5	13
Εκφώνηση	13
Λύση	13
Άσκηση 9: 7.3.2	14
Εκφώνηση	14
Λύση	14
Exhaustive Search: Κώδικας	14
Άσκηση 10: 7.4.1	15
Εκφώνηση	15
Λύση	15

Άσκηση 1

Εκφώνησηση

Έστω ένα σύνολο U . Μια οικογένεια συναρτήσεων κατακερματισμού $\mathcal{H} = \{h : U \rightarrow [m]\}$ λέγεται καθολική αν $\forall x, y \in U, x \neq y : \Pr_{h \in \mathcal{H}}[h(x) = h(y)] \leq \frac{1}{m}$

Ισοδύναμα, για κάθε δύο διαφορετικές τιμές $x, y \in U$, υπάρχουν το πολύ $|\mathcal{H}|/m$ συναρτήσεις $h \in \mathcal{H}$ για τις οποίες $h(x) = h(y)$.

Σημείωση: χρησιμοποιούμε τον συμβολισμό $[m] = \{0, \dots, m-1\}$.

- (α) Αποδείξτε ότι για $a \in [m] \setminus \{0\}, b \in [m]$ η οικογένεια συναρτήσεων $h_{a,b}(x) = (ax + b) \bmod m$ δεν έχει την ιδιότητα της καθολικότητας για $U = [m^k], k \geq 2$.
- (β) Εξηγήστε αν και γιατί ισχύει ότι για πρώτο αριθμό $p > |U| = m^k, k \geq 2$ και για $a \in [p] \setminus \{0\}, b \in [p]$ η οικογένεια συναρτήσεων $h_{a,b}(x) = ((ax + b) \bmod p) \bmod m$ έχει την ιδιότητα της καθολικότητας.
- (γ) Δώστε ένα συγκεκριμένο παράδειγμα της παραπάνω ιδιότητας, για $m = 7, p = 53, k = 2$ και πέντε ζεύγη κλειδιών (x_i, y_i) της επιλογής σας. Δείξτε για ποιες συναρτήσεις της οικογένειας τα ζεύγη κλειδιών που επιλέξατε έχουν την ίδια hash value και για ποιες έχουν διαφορετική.
- (δ) Εξακολουθεί να ισχύει η ιδιότητα της καθολικότητας αν στο ερώτημα (β) δέσουμε $U = [p^2]$; Εξηγήστε την απάντησή σας.

Λύση

- (α) Για $m \geq 2$ και $k \geq 2$, η οικογένεια

$$\mathcal{H} = \{ h_{a,b}(x) = (ax + b) \bmod m \mid a \in \{1, \dots, m-1\}, b \in \{0, \dots, m-1\} \}$$

δεν είναι καθολική στο $U = [m^k]$.

Πράγματι, αρχικά παρατηρούμε ότι:

$$|\mathcal{H}| = |\{a \in \{1, \dots, m-1\}\}| \times |\{b \in \{0, \dots, m-1\}\}| = (m-1)m.$$

Α.ν.δ.ο. $\exists i_1, i_2 \in [m^k], k \geq 2, i_1 \neq i_2 : |\{h_{a,b} \in \mathcal{H} \mid h_{a,b}(i_1) = h_{a,b}(i_2)\}| > \frac{|\mathcal{H}|}{m} = m-1$.

Αφού $U = [m^k]$ με $k \geq 2$, υπάρχουν i, j που διαφέρουν κατά κάποιο πολλαπλάσιο του m .

Για παράδειγμα, θεωρούμε

$$i_1 = r, \quad i_2 = r + m,$$

όπου $0 \leq r < m^k - m$.

Τότε ισχύει ότι

$$i \neq j \quad \text{και} \quad i \equiv j \pmod{m}.$$

Για αυτά τα i_1, i_2 παρατηρούμε ότι: για κάθε $a \in [m] \setminus \{0\}, b \in [m]$ ισχύει ότι

$$h_{a,b}(i_1) = (a i_1 + b) \bmod m, \quad h_{a,b}(i_2) = (a i_2 + b) \bmod m.$$

Αλλά αφού $i_2 - i_1 \equiv 0 \pmod{m}$ έπεται ότι

$$a(i_2 - i_1) \equiv 0 \pmod{m}, \quad \text{άρα}$$

$$(a i_1 + b) \equiv (a i_2 + b) \pmod{m}.$$

$$\text{Συνεπώς } h_{a,b}(i_1) = h_{a,b}(i_2).$$

Εφόσον κάθε συνάρτηση της $\mathcal{H}$ ικανοποιεί $h(i) = h(j)$, έχουμε

$$|\{h \in \mathcal{H} : h(i) = h(j)\}| = |\mathcal{H}| = m(m-1) > m-1.$$

(6) Αρχικά για κάθε $a \in \{1, \dots, p-1\}$ και κάθε $b \in \{0, \dots, p-1\}$, ορίζουμε την συνάρτηση

$$g_{a,b}(x) = ax + b \pmod{p}$$

Για κάθε τέτοια g ορίζουμε μια hash function:

$$h_{a,b}(x) = g_{a,b}(x) \pmod{m}$$

Κάθε σύγκρουση $h_{a,b}(x) = h_{a,b}(y)$ προέρχεται από ζεύγη $s, t \in \{0, 1, \dots, p-1\}$ με $s \equiv t \pmod{m}$, $s := g_{a,b}(x)$ και $t := g_{a,b}(y)$.

Πριν μετρήσουμε όμως τα (s, t) , παρατηρούμε ότι $g_{a,b}(x) \neq g_{a,b}(y)$.

Αυτό ισχύει διότι αν $ax + b \equiv ay + b \pmod{p}$, τότε $a(x - y) \equiv 0 \pmod{p}$

Δεδομένου ότι $a \not\equiv 0 \pmod{p}$, έπεται ότι $x \equiv y \pmod{p}$, άτοπο αφού $x \neq y$ και $p > |U|$.

Άρα πρέπει να μετρήσουμε τα ζεύγη (s, t) με $s \equiv t \pmod{m}$ και $s \neq t$.

Υπάρχουν p επιλογές για το s . Θεωρώντας σταθερό το s , υπάρχουν $\lceil p/m \rceil$ τιμές του $t \in \{0, \dots, p-1\}$ τ.ω. $s \equiv t \pmod{m}$ και αποκλείοντας την περίπτωση $t = s$ καταλήγουμε σε $\lceil p/m \rceil - 1$ επιλογές του t για κάθε επιλογή του s .

Πολλαπλασιάζουμε και καταλήγουμε ότι το συνολικό πλήθος s, t είναι $p(\lceil p/m \rceil - 1)$.

Παρατηρούμε επίσης ότι:

$$\lceil \frac{p}{m} \rceil \leq \frac{p+m-1}{m} \implies \lceil \frac{p}{m} \rceil - 1 \leq \frac{p+m-1}{m} - \frac{m}{m} \implies p(\lceil \frac{p}{m} \rceil - 1) \leq p \left(\frac{p-1}{m} \right)$$

Τέλος για κάθε ζεύγος (s, t) που μετρήσαμε θα μετρήσουμε πόσα ζεύγη (a, b) υπάρχουν ώστε $g_{a,b}(x) = s \pmod{p}$ και $g_{a,b}(y) = t \pmod{p}$.

Με άλλα λόγια ρωτάμε πόσες τιμές $a, b \in \{0, \dots, p-1\}$ ικανοποιούν το σύστημα:

$$\begin{cases} ax + b \equiv s \pmod{p}, \\ ay + b \equiv t \pmod{p} \end{cases}$$

Το όποιο γνωρίζουμε από την γραμμική άλγεβρα ότι έχει μοναδική λύση (a, b) με $a \not\equiv 0 \pmod{p}$.

Συνεπώς ο συνολικός αριθμός ζευγών (a, b) με $h_{a,b}(x) = h_{a,b}(y)$ δεν υπερβαίνει $\frac{p(p-1)}{m}$.

Αφού υπάρχουν $p(p-1)$ συναρτήσεις στην οικογένειά μας η πιθανότητα να επιλέξουμε μία που να δημιουργεί collision είναι το πολύ $\frac{1}{m}$.

Συνεπώς η οικογένειά μας είναι όντως καθολική.

(γ) Θα εκτελέσουμε μια (λιγότερο μαθηματική αλλά) προγραμματιστική προσέγγιση.

Επιλέγουμε 5 ζεύγη κλειδιών και θα τρέξουμε τον κώδικα σε *python* ώστε να υπολογίσει το πλήθος των collisions.

Έστω ότι $m = 7, p = 53, k = 2$.

Έστω $U = [7^2] = \{0, 1, \dots, 48\}$. Επιλέγουμε πέντε ζεύγη κλειδιών:

$$(x_1, y_1) = (0, 1), (x_2, y_2) = (5, 12), (x_3, y_3) = (10, 20), (x_4, y_4) = (7, 14), (x_5, y_5) = (17, 33).$$

Ο συνολικός αριθμός συναρτήσεων της οικογένειας είναι

$$|\mathcal{H}| = p(p-1) = 53 \cdot 52 = 2756,$$

και το όριο σύγκρουσης σε καθολική οικογένεια είναι

$$\frac{|\mathcal{H}|}{m} = \frac{2756}{7} \approx 393.7.$$

Παρακάτω φαίνεται ο Python κώδικας που χρησιμοποιήθηκε για τον υπολογισμό του πλήθους των συναρτήσεων (a, b) που συγκρούουν κάθε ζεύγος:

Πίνακας 1: Αριθμός συγκρούσεων για τα επιλεγμένα ζεύγη

x	y	# συγκρούσεων	Σύνολο συναρτήσεων	Όριο $ \mathcal{H} /m$
0	1	350	2756	≈ 393.7
5	12	350	2756	≈ 393.7
10	20	350	2756	≈ 393.7
7	14	350	2756	≈ 393.7
17	33	350	2756	≈ 393.7

```

1  # Parameters
2  m = 7
3  p = 53
4  total_functions = p * (p - 1)
5
6  # Selected key-pairs
7  pairs = [
8      (0, 1),
9      (5, 12),
10     (10, 20),
11     (7, 14),
12     (17, 33)
13 ]
14
15 # Function to count collisions for a given pair (x, y)
16 def count_collisions(x, y):
17     count = 0
18     for a in range(1, p):          # a from 1 to p-1
19         for b in range(p):          # b from 0 to p-1
20             # compute  $h_{\{a,b\}}(x)$  and  $h_{\{a,b\}}(y)$ 
21             hx = ((a * x + b) % p) % m
22             hy = ((a * y + b) % p) % m
23             if hx == hy:
24                 count += 1
25     return count
26
27 # Print summary and results
28 print(f"Total functions: {total_functions}")
29 print(f"Universal bound (total/m): {total_functions/m:.2f}\n")
30 for x, y in pairs:
31     coll = count_collisions(x, y)
32     print(f"Pair ({x}, {y}): {coll} collisions")

```

- (δ) Αν τώρα πάρουμε $U = [53^2]$, δηλαδή κλειδιά μέχρι 2808, τότε υπάρχουν $x \neq y \in U$ με $x \equiv y \pmod{53}$. Για κάθε τέτοιο ζεύγος:

$$g_{a,b}(x) \equiv ax + b \equiv ay + b \equiv g_{a,b}(y) \pmod{53},$$

άρα και $(g_{a,b}(x) \bmod 7) = (g_{a,b}(y) \bmod 7)$.

Δηλαδή κάθε $h_{a,b}$ συγκρούει αυτά τα x, y , οπότε $|\{h : h(x) = h(y)\}| = |\mathcal{H}|$, που είναι πολύ μεγαλύτερο από $|\mathcal{H}|/7$. Συνεπώς η ιδιότητα της καθολικότητας χαλάει για $U = [53^2]$.

Άσκηση 2

Εκφώνηση

Εξετάστε την μέθοδο κατακερματισμού ανοιχτής διευθυνσιοδότησης (open addressing) και:

- (α) Εξηγήστε γιατί ο μέσος χρόνος επιτυχούς αναζήτησης, μετά από εισαγωγή n στοιχείων, είναι ίδιος με τον μέσο χρόνο εισαγωγής των στοιχείων στον πίνακα.
- (β) Αποδείξτε ότι ο χρόνος αυτός φράσσεται άνω από την ποσότητα $\frac{1}{\alpha} \ln \frac{1}{(1-\alpha)}$, όπου $\alpha = \frac{n}{m}$ ο παράγοντας φόρτου.
Υπόδειξη: ξεκινήστε με μια εκτίμηση για το αναμενόμενο πλήθος δοκιμών κατά την εισαγωγή του i -οστού στοιχείου υποθέτοντας uniform hashing.

Λύση

- (α) Ο χρόνος επιτυχούς αναζήτησης ενός στοιχείου (όπως και ο χρόνος διαγραφής ενός στοιχείου) ισούται με τον αρχικό χρόνο εισαγωγής του στοιχείου. Επομένως θεωρώντας μέση τιμή η ισότητα αυτή διατηρείται.
Ο λόγος που ισχύει αυτό είναι διότι ο αλγόριθμος ακολουθάει την ίδια διαδικασία (ανεξάρτητα με το αν η μετάθεση των κελιών ήταν τυχαία), συνεπώς αν εισήγαγε πρώτη φορά το στοιχείο μετά από χρόνο t , η εύρεση του θα χρειαστεί πάλι χρόνο t .
- (β) Όπως έχουμε αναφέρει ο μέσος χρόνος επιτυχούς αναζήτησης του στοιχείου k ισούται με τον μέσο χρόνο αρχικής εισαγωγής του στον πίνακα.
Έστω ότι το στοιχείο k ήταν το $(i+1)$ -οστό στοιχείο που προστέθηκε, δηλαδή ήταν ήδη παρόντα i .
Έχοντας λοιπόν i στοιχεία σε ένα πίνακα μεγέθους m , ο αναμενόμενος χρόνος εισαγωγής μέχρι να βρεθεί το $i+1$ -οστό στοιχείο, δηλαδή ο αναμενόμενος χρόνος μέχρι να βρεθεί κενό κελί είναι:

$$\frac{1}{1 - \frac{i}{m}} = \frac{m}{m - i}.$$

Ο μέσος αριθμός προβολών για n κλειδιά είναι

$$E[\text{Επιτυχής Αναζήτηση}] = \frac{1}{n} \sum_{i=0}^{n-1} \frac{m}{m-i} = \frac{m}{n} \sum_{k=m-n+1}^m \frac{1}{k}.$$

Εφαρμόζοντας την ανισότητα $\sum_{k=a}^b \frac{1}{k} \leq \int_{a-1}^b \frac{dx}{x} = \ln \frac{b}{a-1}$, (η οποία ισχύει εξ ορισμού του ολοκληρώματος) έχουμε:

$$E[\text{Επιτυχής Αναζήτηση}] \leq \frac{m}{n} \ln\left(\frac{m}{m-n}\right) = \frac{1}{\alpha} \ln\left(\frac{1}{1-\alpha}\right),$$

όπου $\alpha = n/m$.

Άσκηση 3

Εκφώνηση

Άσκηση 6.3.1

Here is a collection of twelve baskets. Each contains three of the six items 1 through 6.

$\{1, 2, 3\}$	$\{2, 3, 4\}$	$\{3, 4, 5\}$	$\{4, 5, 6\}$
$\{1, 3, 5\}$	$\{2, 4, 6\}$	$\{1, 3, 4\}$	$\{2, 4, 5\}$
$\{3, 5, 6\}$	$\{1, 2, 4\}$	$\{2, 3, 5\}$	$\{3, 4, 6\}$

Suppose the support threshold is 4. On the first pass of the PCY Algorithm we use a hash table with 11 buckets, and the set $\{i, j\}$ is hashed to bucket $i \times j \bmod 11$.

- (a) By any method, compute the support for each item and each pair of items.
- (b) Which pairs hash to which buckets?
- (c) Which buckets are frequent?
- (d) Which pairs are counted on the second pass of the PCY Algorithm?

Άσκηση 6.3.4

Suppose we perform the PCY Algorithm to find frequent pairs, with market-basket data meeting the following specifications:

1. The support threshold is 10,000.
2. There are one million items, represented by the integers 0, 1, ..., 999999.
3. There are 250,000 frequent items, that is, items that occur 10,000 times or more.
4. There are one million pairs that occur 10,000 times or more.
5. There are P pairs that occur exactly once and consist of two frequent items.
6. No other pairs occur at all.
7. Integers are always represented by 4 bytes.
8. When we hash pairs, they distribute among buckets randomly, but as evenly as possible; i.e., you may assume that each bucket gets exactly its fair share of the P pairs that occur once.

Suppose there are S bytes of main memory. In order to run the PCY Algorithm successfully, the number of buckets must be sufficiently large that most buckets are not frequent. In addition, on the second pass, there must be enough room to count all the candidate pairs. As a function of S , what is the largest value of P for which we can successfully run the PCY Algorithm on this data?

Λύση

Λύση 6.3.1

(α) Υποστήριξη μεμονωμένων αντικειμένων:

στοιχείο i	1	2	3	4	5	6
υποστήριξη $\text{sup}(i)$	4	6	8	8	6	4

Υποστήριξη ζευγών ($i < j$):

ζεύγος (i, j)	(1,2)	(1,3)	(1,4)	(1,5)	(1,6)	(2,3)	(2,4)	(2,5)
sup	2	3	2	1	0	3	4	2
ζεύγος (i, j)	(2,6)	(3,4)	(3,5)	(3,6)	(4,5)	(4,6)	(5,6)	
sup	1	4	4	2	3	3	2	

(β) Κατακερματισμός ζευγών:

ζεύγος (i, j)	(1,2)	(1,3)	(1,4)	(1,5)	(1,6)	(2,3)	(2,4)	(2,5)
κάδος	2	3	4	5	6	6	8	10
ζεύγος (i, j)	(2,6)	(3,4)	(3,5)	(3,6)	(4,5)	(4,6)	(5,6)	
κάδος	1	1	4	7	9	2	8	

(γ) Συχνά (frequent) κουτιά: Από την πρώτη διέλευση, οι μετρήσεις ανά κάδο είναι:

$$\{0, 5, 5, 3, 6, 1, 3, 2, 6, 3, 2\}$$

για τους κάδους 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10 αντίστοιχα. Με κατώφλι 4, οι συχνοί κάδοι είναι

$$\{1, 2, 4, 8\}.$$

(δ) Ζεύγη στη δεύτερη διέλευση: Κρατούμε όσα ζεύγη έχουν τον κάδο τους σε $\{1, 2, 4, 8\}$ (και τα στοιχεία είναι όλα συχνά). Συγκεκριμένα:

- Κάδος 1: (2, 6), (3, 4)
- Κάδος 2: (1, 2), (4, 6)
- Κάδος 4: (1, 4), (3, 5)
- Κάδος 8: (2, 4), (5, 6)

Άρα ελέγχονται τα ζεύγη:

$$\{1, 2\}, \{1, 4\}, \{2, 4\}, \{2, 6\}, \{3, 4\}, \{3, 5\}, \{4, 6\}, \{5, 6\}.$$

Λύση 6.3.4

Άσκηση 4

Εκφώνηση

- (α) Εξηγήστε συνοπτικά την ορδότητα της μεθόδου A-priori για το πρόβλημα της εξόρυξης συχνών συνόλων στοιχείων (frequent itemset mining) από δεδομένα τύπου ‘καλαδιού αγορών’ (market basket data). Πόσες διασχίσεις (passes) πραγματοποιούνται στην βάση δεδομένων;
- (β) Εξηγήστε γιατί η χρονική πολυπλοκότητα του αλγορίθμου A-priori είναι πολυωνυμική ως προς την έξοδο.
- (γ) Συζητήστε αν η πολυπλοκότητα του αλγορίθμου FP-Growth είναι επίσης πολυωνυμική ως προς την έξοδο.

Λύση

- (α) Η ορδότητα της μεθόδου A-priori στηρίζεται στην αντιμονωτικότητα (anti-monotonicity). Έχουμε αποδείξει ότι αν ένα itemset I είναι frequent τότε κάθε $J \subseteq I$ είναι frequent. Ισοδύναμα (αντιθετοαντιστροφή) αν ένα σύνολο στοιχείων (itemset) δεν είναι συχνό, τότε κανένα από τα υπερσύνολά του δεν μπορεί να είναι συχνό. Επομένως αντί να μετράμε το πλήθος εμφάνισης κάθε δυνατού συνδυασμού επικεντρωνόμαστε μόνο σε ελέγχους συνόλων που προέρχονται από frequent itemsets.

Ο αλγόριθμος A-priori απαιτεί μία πλήρη διάσχιση της βάσης δεδομένων ανά επίπεδο k ώστε να μετρήσει τα supports των υποψήφιων συνόλων από k -άδες.

Συνεπώς αν το μέγιστο μέγεθος συχνών συνόλων που βρούμε είναι $k_{\max}$, τότε θα απαιτηθούν $k_{\max}$ διασχίσεις της βάσης.

- (β) Ο αλγόριθμος είναι πολυωνυμικού χρόνου ως προς την έξοδο γιατί σε κάθε βήμα k ο υπολογισμός των frequent itemsets είναι τετραγωνικός ως προς το πλήθος τους. Επίσης αφού σε κάθε βήμα παράγεται τουλάχιστον ένα frequent itemset το πλήθος των επιπέδων $k_{\max}$ φράσσεται επίσης πολυωμικά ως προς το μέγεθος της εξόδου. Συνεπώς ο συνολικός αλγόριθμος είναι πολυωνυμικού χρόνου ως προς την έξοδο.
- (γ) Ο αλγόριθμος FP-Growth είναι *output-polynomial* (και υποστηρίζει επίσης *πολυωνυμική καθυστέρηση* (polynomial delay) κατά την εξαγωγή όλων των συχνών υποσυνόλων).

Η κατασκευή του FP-δένδρου πραγματοποιείται με δύο διελεύσεις πάνω στη βάση δεδομένων και απαιτεί χρόνο γραμμικό ως προς το μέγεθος της βάσης και επομένως ως προς τον αριθμό των συχνών αντικειμένων.

Η εξαγωγή των κανόνων γίνεται αναδρομικά με τη δημιουργία conditional FP-trees. Κάθε βήμα εκτελείται με κόστος πολυωνυμικό στο μέγεθος του αντίστοιχου υποδένδρου.

Συνολικά, ο συνολικός χρόνος εκτέλεσης εκφράζεται ως πολώνυμο του μεγέθους εισόδου και του συνολικού μεγέθους όλων των εξόδων:

$$O(p(|D|, \sum_{f \in F} |f|)),$$

όπου $|D|$ είναι το μέγεθος της βάσης δεδομένων και $\sum_{f \in F} |f|$ το αθροιστικό κόστος από το κάθε υποδέντρο.

Άσκηση 5

Εκφώνηση

- (α) Εκτελέστε τον αλγόριθμο A-priori στο παρακάτω παράδειγμα. Υποθέστε ότι το κατώφλι στήριξης είναι $s = 5$.

$\{abcd\}$	$\{bd\}$	$\{acd\}$	$\{bd\}$
$\{ad\}$	$\{a\}$	$\{abd\}$	$\{bcd\}$
$\{bd\}$	$\{abd\}$	$\{ac\}$	$\{ac\}$
$\{abcd\}$	$\{b\}$	$\{bc\}$	$\{acd\}$
$\{bc\}$	$\{bd\}$	$\{abcd\}$	$\{bcd\}$

- (β) Βρείτε όλους τους κανόνες συσχέτισης που έχουν στήριξη (support) τουλάχιστον 5 και confidence τουλάχιστον 60%. Εξηγήστε με ποιον τρόπο θα αξιοποιήσετε την αντιμονοτονικότητα του confidence ως προς το δεξί μέρος (RHS) των κανόνων.
- (γ) Εκτελέστε τον αλγόριθμο του Τοϊνονεν στο ίδιο παράδειγμα, θεωρώντας ότι το δείγμα είναι οι 8 εγγραφές των 2 επάνω γραμμών. Χρησιμοποιήστε ως κατώφλι στο δείγμα $s' = 2$ και $s'' = 1$ (θα κάνετε δύο διαφορετικές εκτελέσεις του αλγορίθμου). Τι παρατηρείτε;

Λύση

- (α) Εκτέλεση αλγορίθμου A-Priori (min support = 5):

1. Κατασκευή C_1 και έπειτα L_1

Στοιχείο	Στήριξη (count)
a	11
b	14
c	11
d	14

Όλα τα μοναδιαία εμφανίζονται ≥ 5 φορές, άρα

$$L_1 = \{a, b, c, d\}.$$

2. C_2 από L_1 (δυάδες): ab, ac, ad, bc, bd, cd

Ζεύγος	Στήριξη
ab	5
ac	7
ad	8
bc	7
bd	10
cd	7

Όλα ≥ 5 , οπότε

$$L_2 = \{ab, ac, ad, bc, bd, cd\}.$$

3. C_3 από L_2 (τριάδες: abc, abd, acd, bcd)

Τριάδα	Στήριξη
abc	3 (< 5)
abd	5
acd	5
bcd	6

Απορρίπτεται το itemset abc, άρα

$$L_3 = \{abd, acd, bcd\}.$$

4. C_4 : Το itemset $\{a, b, c, d\}$ απορρίπτεται επειδή το υποσύνολο $abc \notin L_3$.

(6) Κανόνες συσχέτισης με $\text{sup} \geq 5$ και $\text{conf} \geq 0.6$:

1. Από L_2 :

Κανόνας	support	confidence
$a \rightarrow c$	7	0.636
$c \rightarrow a$	7	0.636
$a \rightarrow d$	8	0.727
$c \rightarrow b$	7	0.636
$b \rightarrow d$	10	0.714
$d \rightarrow b$	10	0.714
$c \rightarrow d$	7	0.636

2. Από L_3 :

Κανόνας	support	confidence
$ab \rightarrow d$	5	1.000
$ad \rightarrow b$	5	0.625
$ac \rightarrow d$	5	0.714
$ad \rightarrow c$	5	0.625
$cd \rightarrow a$	5	0.714
$bc \rightarrow d$	6	0.857
$bd \rightarrow c$	6	0.600
$cd \rightarrow b$	6	0.857

3. **Pruning (αντιμονοτονικότητα) confidence:**

Για σταθερό X , αν $Y' \supset Y$, τότε

$$\text{conf}(X \rightarrow Y') \leq \text{conf}(X \rightarrow Y).$$

Άρα, αν $\text{conf} < 0.6$ για $X \rightarrow Y$, απορρίπτονται όλοι οι κανόνες $X \rightarrow Y'$ με $Y' \supset Y$.

(γ) **Πρώτη εκτέλεση:**

Θα τρέξουμε τον αλγόριθμο Τοινονεν αρχικά για $s' = 1$ του δείγματος.

Επιλέγουμε το δείγμα μας (πρώτα 8 καλάδια) και τρέχουμε τον Apriori για αυτά με $s = 1$:

1-itemsets (L_1)

Item	Support
a	5
b	5
c	3
d	7

2-itemsets (L_2)

Itemset	Support
$\{a, b\}$	2
$\{a, c\}$	2
$\{a, d\}$	4
$\{b, c\}$	2
$\{b, d\}$	5
$\{c, d\}$	3

3-itemsets (L_3)

Itemset	Support
$\{a, b, c\}$	1
$\{a, b, d\}$	2
$\{a, c, d\}$	2
$\{b, c, d\}$	2

4-itemsets (L_4)

Itemset	Support
$\{a, b, c, d\}$	1

Επομένως κάθε στοιχείο βρέθηκε frequent και συνεπώς το negative border είναι κενό.

Άρα, βρήκαμε όλα τα frequent itemsets ($\{abcd, abc, abd, acd, cbd, ab, ac, bc, a, b, c\}$) με support threshold $s = 1$ στο δείγμα.

Αφού το δείγμα αποτελεί $8/20 = 1/2.5$, θεωρώντας ως ολικό threshold το $(1 \cdot 2.5) = 2.5$ παρατηρούμε ότι έχουμε πάρα πολλά false positives.

Δεύτερη εκτέλεση

Θα τρέξουμε τον αλγόριθμο Τοινωνen τώρα για $s'' = 2$.

Επιλέγουμε το δείγμα μας (πρώτα 8 καλάδια) και τρέχουμε τον Apriori για αυτά με $s = 2$:

1-itemsets (L_1)

Item	Support
a	5
b	5
c	3
d	7

2-itemsets (L_2)

Itemset	Support
$\{a, b\}$	2
$\{a, c\}$	2
$\{a, d\}$	4
$\{b, c\}$	2
$\{b, d\}$	5
$\{c, d\}$	3

3-itemsets (L_3)

Itemset	Support
$\{a, b, d\}$	2
$\{a, c, d\}$	2
$\{b, c, d\}$	2

4-itemsets (L_4)

None (no 4-itemset has support ≥ 2).

Επομένως το negative border είναι το $NegBorder = \{\{a, b, c\}\}$.

Αφού το δείγμα αποτελεί $8/20 = 1/2.5$, θεωρώντας ότι ολικό threshold $(2 \cdot 2.5) = 5$.

Παρατηρούμε ότι το NegBorder δεν είναι όντως frequent στο ολικό dataset και ο αλγόριθμος έχει βρει σωστά τα frequent itemsets.

Άσκηση 6: 7.2.2

Εκφώνηση

How would the clustering of Example 7.2 change if we used for the distance between two clusters:

- (a) The minimum of the distances between any two points, one from each cluster.
- (b) The average of the distances between pairs of points, one from each of the two clusters.

Λύση

Στο παράδειγμα η απόσταση μεταξύ δύο clusters ορίζεται ως η απόσταση μεταξύ των centroids.

- (a) Σε αυτή την περίπτωση ορίζουμε ως απόσταση μεταξύ των clusters την ελάχιστη μεταξύ των σημείων τους.
Στο συγκεκριμένο παράδειγμα, αρχικά θα δημιουργηθεί ο ίδιος cluster $\{(11, 4), (12, 3)\}$ και έπειτα ο ίδιος cluster θα μεγεθυνθεί σε $\{(11, 4), (12, 3), (10, 5)\}$.
Αυτό ισχύει διότι οι κοντινότεροι clusters πριν την συνένωση ήταν οι $\{(11, 4), (12, 3)\}$ και $\{(10, 5)\}$. Παρατηρούμε δηλαδή συνένωση διαφορετικών clusters από το παράδειγμα 7.2.
- (b) Η μετρική *Average Linkage* ορίζεται ως ο μέσος όρος των αποστάσεων όλων των ζευγών σημείων από δύο clusters A και B :

$$d_{\text{avg}}(A, B) = \frac{1}{|A||B|} \sum_{a \in A} \sum_{b \in B} \|a - b\|$$

Όπου $\|a - b\|$ είναι η Ευκλείδεια απόσταση μεταξύ των σημείων a και b .
Οι πρώτες δύο συγχωνεύσεις γίνονται ως εξής:

1. Συγχώνευση των σημείων $(11, 4)$ και $(10, 5)$ με απόσταση περίπου 1.41, δίνοντας νέο cluster $\{(11, 4), (10, 5)\}$
2. Συγχώνευση των σημείων $(4, 10)$ και $(4, 8)$ με απόσταση 2.00, δίνοντας νέο cluster $\{(4, 10), (4, 8)\}$

Άσκηση 7: 7.2.3

Εκφώνηση

Repeat the clustering of Example 7.2 if we choose to merge the two clusters whose resulting cluster has:

- (a) The smallest radius.
- (b) The smallest diameter.

Λύση

(α) Συγχώνευση με ελάχιστη ακτίνα

1. Συγχώνευση των σημείων $(11, 4)$ και $(10, 5)$: centroid $\mu = (10.5, 4.5)$,

$$\text{ακτίνα} = \max\{\|(11, 4) - \mu\|, \|(10, 5) - \mu\|\} = 0.7071.$$

2. Συγχώνευση των σημείων $(4, 10)$ και $(4, 8)$: centroid $\mu = (4, 9)$,

$$\text{ακτίνα} = \max\{\|(4, 10) - \mu\|, \|(4, 8) - \mu\|\} = 1.0000.$$

(β) Συγχώνευση με ελάχιστη διάμετρο

1. Συγχώνευση των σημείων $(11, 4)$ και $(10, 5)$:

$$\text{διάμετρος} = \|(11, 4) - (10, 5)\| = \sqrt{2} \approx 1.4142.$$

2. Συγχώνευση των σημείων $(4, 10)$ και $(4, 8)$:

$$\text{διάμετρος} = \|(4, 10) - (4, 8)\| = 2.0000.$$

Άσκηση 8: 7.2.5

Εκφώνηση

We can select clustroids for clusters, even if the space is Euclidean. Consider the three natural clusters in Fig. 7.2, and compute the clustroids of each, assuming the criterion for selecting the clustroid is the point with the minimum sum of distances to the other points in the cluster.

Λύση

Cluster	Σημείο	Άθροισμα αποστάσεων
1	(4, 10)	7.8284
1	(7, 10)	8.8417
1	(4, 8)	7.6056
1	(6, 8)	7.0645
2	(3, 4)	5.0645
2	(2, 2)	5.2361
2	(5, 2)	5.8284
3	(12, 6)	11.7148
3	(10, 5)	8.7148
3	(11, 4)	7.3006
3	(9, 3)	11.7148
3	(12, 3)	10.2426

Συνοψίζοντας:

- Clustroid of Cluster 1: (6, 8) (με άθροισμα 7.0645)
- Clustroid of Cluster 2: (3, 4) (με άθροισμα 5.0645)
- Clustroid of Cluster 3: (11, 4) (με άθροισμα 7.3006)

Άσκηση 9: 7.3.2

Εκφώνηση

Prove that no matter what point we start with in Fig. 7.8, if we select three starting points by the method of Section 7.3.2 we obtain points in each of the three clusters. *Hint:* You could solve this exhaustively by beginning with each of the twelve points in turn. However, a more generally applicable solution is to consider the diameters of the three clusters and also consider the *minimum intercluster distance*, that is, the minimum distance between two points chosen from two different clusters. Can you prove a general theorem based on these two parameters of a set of points?

Λύση

Exhaustive Search: Κώδικας

Παρακάτω φαίνεται ο κώδικας σε python για την απόδειξη μέσω exhaustive search:

```
1      import numpy as np
2
3      # Define the points and their true clusters
4      points = [
5          (4, 10, 'C1'), (7, 10, 'C1'), (4, 8, 'C1'), (6, 8, 'C1'),
6          (5, 2, 'C2'), (3, 4, 'C2'), (2, 2, 'C2'),
7          (10, 5, 'C3'), (12, 3, 'C3'), (12,6, 'C3'), (11,4, 'C3'), (9, 3, 'C3')
8      ]
9
10     # Euclidean distance function
11     def distance(a, b):
12         return np.hypot(a[0] - b[0], a[1] - b[1])
13
14     # Perform farthest-first selection for each possible starting point
15     results = []
16     for p1 in points:
17         # 1) Find the second seed as the point farthest from p1
18         dists = [(distance(p1, p), p) for p in points if p != p1]
19         p2 = max(dists, key=lambda x: x[0])[1]
20
21         # 2) Find the third seed by maximizing the minimum distance to {p1, p2}
22         dmin = []
23         for p in points:
24             if p in (p1, p2):
25                 continue
26             dmin_val = min(distance(p, p1), distance(p, p2))
27             dmin.append((dmin_val, p))
28         p3 = max(dmin, key=lambda x: x[0])[1]
29
30         results.append((p1, p2, p3))
31
32     # Print the results
33     print("Start\tCluster\t2nd Seed\tCluster\t3rd Seed\tCluster")
34     for (x1,y1,c1),(x2,y2,c2),(x3,y3,c3) in results:
35         print(f"({x1},{y1})\t{c1}\t({x2},{y2})\t{c2}\t({x3},{y3})\t{c3}")
```

Παρακάτω στον πίνακα φαίνονται αναλυτικά τα αποτελέσματα:

Αρχικό Σημείο	Cluster	1ο Απόμακρο	Cluster	2ο Απόμακρο	Cluster
(4,10)	C ₁	(12,3)	C ₃	(2,2)	C ₂
(7,10)	C ₁	(2,2)	C ₂	(12,3)	C ₃
(4,8)	C ₁	(12,3)	C ₃	(2,2)	C ₂
(6,8)	C ₁	(12,3)	C ₃	(2,2)	C ₂
(5,2)	C ₂	(7,10)	C ₁	(12,3)	C ₃
(3,4)	C ₂	(12,6)	C ₃	(7,10)	C ₁
(2,2)	C ₂	(12,6)	C ₃	(4,10)	C ₁
(10,5)	C ₃	(2,2)	C ₂	(4,10)	C ₁
(12,3)	C ₃	(4,10)	C ₁	(2,2)	C ₂
(12,6)	C ₃	(2,2)	C ₂	(4,10)	C ₁
(11,4)	C ₃	(4,10)	C ₁	(2,2)	C ₂
(9,3)	C ₃	(4,10)	C ₁	(2,2)	C ₂

Πίνακας 2: Αποτελέσματα της farthest first εκκίνησης για $k = 3$.

Άσκηση 10: 7.4.1

Εκφώνηση

Consider two clusters that are a circle and a surrounding ring, as in the running example of this section. Suppose:

- The radius of the circle is c .
- The inner and outer circles forming the ring have radii i and o , respectively.
- All representative points for the two clusters are on the boundaries of the clusters.
- Representative points are moved 20% of the distance from their initial position toward the centroid of their cluster.
- Clusters are merged if, after repositioning, there are representative points from the two clusters at distance d or less.

In terms of d , c , i , and o , under what circumstances will the ring and circle be merged into a single cluster?

Λύση

Έστω οι δύο clusters:

- Κύκλος ακτίνας c .
- Δακτύλιος με εσωτερική ακτίνα i και εξωτερική ακτίνα o .

Οι αντιπρόσωποι μετακινούνται κατά 20% προς το centroid του εκάστοτε cluster.

Χθγ υποθέτουμε ότι το κοινό centroid βρίσκεται στο $(0, 0)$ (ο αλγόριθμος είναι ανεξάρτητος από την θέση του centroid).

Μετά τη μετακίνηση, η ακτίνα του κύκλου γίνεται

$$r'_{\text{κύκλου}} = 0,8c,$$

και η εσωτερική ακτίνα του δακτυλίου

$$r'_{\text{δακτυλίου (εσωτ.)}} = 0,8i.$$

Η νέα απόσταση μεταξύ των κοντινότερων αντιπροσώπων (αφού βρίσκονται στο σύνορο των clusters) γίνεται:

$$\Delta' = 0,8(i - c).$$

Σύμφωνα με το κριτήριο συγχώνευσης:

$$\Delta' \leq d \iff 0,8(i - c) \leq d.$$

Παρατηρούμε ότι το κριτήριο είναι ανεξάρτητο του α .